

OCR-IDP

Số hóa biểu mẫu chứng khoán tiếng Việt thành **JSON**
có cấu trúc.

PDF / Ảnh scan → tiền xử lý → OCR → trích xuất → JSON

- 9 eForm thật
- 27 trang
- 5 bước pipeline

Vì sao cần tự động hóa?

- ◇ Biểu mẫu chứng khoán (mở tài khoản, lệnh, danh sách cổ đông...) phần lớn là **PDF/ảnh scan tiếng Việt**.
- ◇ Nhập liệu thủ công **chậm, dễ sai, khó kiểm soát chất lượng**.
- ◇ Thách thức kỹ thuật: **tiếng Việt có dấu**, layout phức tạp (bảng, checkbox, chữ ký), **tài liệu nhiều trang**, chất lượng scan không đều.
- ◇ Mục tiêu: pipeline **end-to-end** PDF/ảnh → JSON, **đo được độ chính xác**, dễ mở rộng theo từng loại biểu mẫu.

Pipeline module hóa + kiến trúc plugin

01 · PIPELINE

5 bước có interface rõ ràng

Tiền xử lý → OCR → layout → trích xuất → chuẩn hóa/kiểm tra → JSON.

03 · OCR

Đa engine sau 1 interface

RapidOCR, VietOCR, Tesseract, EasyOCR, PaddleOCR.

05 · ĐÁNH GIÁ

So ground-truth

Accuracy, exact-match, P/R/F1 → MD + CSV.

02 · PLUGIN

Mỗi biểu mẫu = 1 plugin

Thêm biểu mẫu mới không cần sửa core.

04 · TRÍCH XUẤT

Hybrid rule + LLM

Rule/anchor/layout, LLM tùy chọn, tự fallback.

06 · DEMO

3 mặt sử dụng

REST API + Web + CLI, đóng gói Docker.

Từ pdf đến JSON, qua 5 bước

PDF /
Ảnh



[1]
Tiền xử lý



[2]
OCR



[3]
Layout



[4]
Trích xuất



[5]
Chuẩn hóa /
Kiểm tra



JSON

Mở rộng mà không chạm vào core

- ◇ Mỗi loại biểu mẫu là 1 plugin trong `src/ocr_idp/forms/<form>/`.
- ◇ Đăng ký qua registry `@register_form` → thêm biểu mẫu mới **không** sửa core.
- ◇ Hiện có plugin `generic`: kết xuất OCR theo **từng trang**.

```
# output của plugin `generic`
{
  "form_type": "generic",
  "page_count": 3,
  "pages": [
    {
      "page_index": 0,
      "n_lines": 42,
      "lines": [ ... ],
      "text": " ... "
    }
  ]
}
```

Những gì hệ thống làm được

TIỀN XỬ LÝ

Làm sạch ảnh

PDF→ảnh (PyMuPDF), deskew, khử nhiễu, binarize, auto-crop; tự phát hiện text-layer.

OCR

5 engine, 1 interface

RapidOCR (mặc định), VietOCR, Tesseract, EasyOCR, PaddleOCR.

TRÍCH XUẤT

Hybrid

Rule/regex + anchor fuzzy + layout + LLM structured output, cấu hình theo trường.

ĐÁNH GIÁ

So ground-truth

Accuracy/trường, exact-match, P/R/F1, thời gian → MD + CSV.

ĐA TRANG

An toàn theo trang

Mỗi dòng mang page_index → không rò rỉ nhãn↔giá trị giữa trang.

LAYOUT

Hiểu cấu trúc

Dòng/section, bảng, checkbox/radio, vùng dấu & chữ ký.

CHUẨN HÓA

Kiểm tra & gấn cờ

Ngày/tiền/mã/tên/địa chỉ; cờ thiếu, sai định dạng, confidence thấp.

DEMO

API · Web · CLI

FastAPI + Streamlit + Typer, chạy chung một Pipeline.

Công nghệ & lý do lựa chọn

- ◇ Ngôn ngữ: **Python**. Triển khai chính bằng **Docker (Python 3.11)** — đóng gói sẵn Tesseract(+vie) & poppler, tương thích torch/paddle.
- ◇ Lý do Docker: host là **Python 3.14**, torch/paddle chưa có wheel 3.14.
- ◇ LLM trong khung trích xuất là **opt-in, mặc định TẮT** — không có key vẫn chạy bằng rule/anchor.
- ◇ Cấu hình tập trung: `configs/default.yaml` + env `OCRIDP_*`; secret để trong `.env`.

THƯ VIỆN CHÍNH

Pillow

numpy

OpenCV

PyMuPDF

scikit-image

rapidocr-onnxruntime

onnxruntime

rapidfuzz

pydantic

typer

REST API · Web · CLI

FASTAPI

REST API

Tích hợp hệ thống khác; tài liệu tại /docs.

STREAMLIT

Web demo

Upload → ảnh tiền xử lý + bbox overlay + JSON + bảng cảnh báo + tải về.

TYPED

CLI

process · batch · evaluate · serve-api · serve-web

METHOD	ENDPOINT	Mô Tả
GET	/health	trạng thái + phiên bản + engine mặc định
GET	/forms	danh sách biểu mẫu hỗ trợ
GET	/engines	engine OCR + tình trạng cài đặt
POST	/process	upload PDF/ảnh (+ form_type, engine) → JSON

9 biểu mẫu eForm

FORM	TRANG	LOẠI
eform1		2 PDF số
eform5		3 Scan
eform7		3 Scan
eform69		3 Scan
eform85		1 Scan
eform92		2 Scan
eform93		3 Scan
eform94		6 Scan
eform100		4 Scan

9 biểu mẫu

27 trang

1 PDF số

8 scan

Ghép cặp theo số **N**:
data/raw/form_N.pdf ⇄ data/ground_truth/expect_N.json

Bộ dữ liệu **hỗn hợp**: 1 PDF số (đọc qua text-layer, chính xác tuyệt đối) và 8 bản scan (bắt buộc OCR — chất lượng phụ thuộc engine).

Theo 3 mức

- ◇ (a) PDF text-layer (eform1): đọc trực tiếp → **chính xác gần tuyệt đối**.
- ◇ (b) OCR bản scan (RapidOCR): tốt cho mã/số/ngày, nhưng **mất dấu tiếng Việt** — "Đỗ Thị An" → "DO ThiAn".
- ◇ (c) Trích xuất theo schema eform: **chưa đo** — chưa xây extractor riêng (mới có generic). Số hiện tại chỉ là **BASELINE**.

Nhận xét: khung pipeline + đo lường đã sẵn sàng; bước tiếp theo là plugin trích xuất chuyên biệt để nâng accuracy thực sự.

Roadmap & trạng thái

● M0–M3	Khung dự án — config/types/CLI/Docker; tiền xử lý; OCR + registry. ✓ xong
● M4–M7	Khung trích xuất — anchor/rule/layout/checkbox/radio/table + LLM + chuẩn hóa/validate. ✓ xong
● M8–M9	OCR đa engine + bộ đánh giá so ground-truth (accuracy/exact/P-R-F1/lỗi → MD/CSV). ✓ xong
● M10–M11	Demo REST API + Web + CLI; hoàn thiện, dọn dead code. ✓ xong
● Tiếp theo	Plugin trích xuất riêng từng eform (khớp expect_N.json); hoặc tăng kiểm tra nghiệp vụ/compliance. ⌚ sắp triển khai

Công việc tiếp theo

HẠN CHẾ

- ◇ Chưa có extractor riêng từng eform → output `generic` ≠ schema kỳ vọng.
- ◇ RapidOCR trên host **mất dấu tiếng Việt** ở tên/địa chỉ.

HƯỚNG PHÁT TRIỂN

- ◇ Plugin trích xuất từng eform khớp `expect_N.json`.
- ◇ VietOCR / LLM-repair để **giữ dấu tiếng Việt**.
- ◇ Tầng **kiểm tra nghiệp vụ / compliance** trên JSON + tóm tắt tự động.

Nền tảng IDP sẵn sàng để nâng cấp

- ◇ Pipeline IDP **end-to-end** chạy thật trên 9 biểu mẫu — module hóa + kiến trúc plugin.
- ◇ Đo lường **minh bạch** so ground-truth; trạng thái được trình bày trung thực.
- ◇ Sẵn sàng để nâng độ chính xác **theo từng biểu mẫu** bằng plugin chuyên biệt.